VOTRE MANDAT

Éprouver l'agent

Demande de Camille, responsable de l'agence

« Votre agent a réussi une démonstration. Nos conseillers rencontrent aussi des demandes vagues, des prix modifiés, des indisponibilités et des erreurs. Montrez-nous quand le parcours reste utile, quand il doit s'arrêter et qui décide de reprendre. »

Mission

Évaluez votre parcours avec **douze cas**, répartis entre demandes normales, ambiguïtés, erreurs et entrées cherchant à détourner ses règles. Définissez les critères avant les essais. Conservez les résultats défavorables et les cas non exécutés. Choisissez une correction, retestez et défendez une décision d'usage.

Contraintes

- Voyages, prestations, prix et réservations sont fictifs.
- Modèles gratuits via OpenRouter ; aucun secours payant automatique.
- Une option exige l'accord explicite du conseiller dans votre application.
- La confirmation reste une action séparée, hors des outils du modèle, après une autre validation humaine.
- Les clés restent hors des prompts, traces, captures et dépôts.
- Un rejeu est annoncé comme tel ; il ne vaut pas démonstration du modèle en direct.

Remise

- Jeu de cas et critères versionnés, modes et nombre d'essais prévus fixés avant campagne.
- Résultats v1/v2 dans des fichiers séparés, traces utiles, modes et essais manquants.
- Diagnostic d'un défaut, correction identifiée et retest.
- Note d'une page : autoriser, limiter ou refuser le parcours, avec preuves, limites, responsable et prochaines vérifications.

Chaque membre explique un cas qu'il a vérifié, une frontière de responsabilité et une décision prise face à l'IA. La quantité de fonctionnalités et l'esthétique de l'interface ne déterminent pas la qualité du travail.